Санкт-Петербургский государственный университет
Кафедра математики и компьютерных наук

Выбор инструментов как поверхностное выравнивание: эффективная адаптация LLM методом LoRA на минимальных наборах данных

Горошко Андрей Витальевич

Научный руководитель: кандидат физ.-мат. наук, ведущий специалист центра ИИ и науки о данных Салищев С. И.

Санкт-Петербург

План доклада

1. Актуальность и постановка задачи
2. Теоретическая основа: гипотеза LIMA
3. Метод LoRA и экспериментальный пайплайн
4. Дизайн эксперимента: обучающие датасеты
5. Результаты: от baseline к дообученным моделям
6. Групповой анализ 12 моделей
7. Статистическая валидация
8. Выводы и практическая значимость

Актуальность

AI-агенты на основе LLM автономно взаимодействуют с внешними сервисами через вызовы инструментов (tool calls). Корректная маршрутизация запроса --- критическая задача.

Существующие подходы:

- Toolformer [3] --- полное дообучение
- Gorilla [4] --- fine-tuning для API
- ToolLLM [5] --- большие датасеты

Общая проблема: требуют значительных вычислительных ресурсов и больших наборов данных.

Открытый вопрос:

Каков *минимально достаточный* объём данных для адаптации LLM к задаче выбора инструмента?

Можно ли обойтись **сотнями** примеров вместо **тысяч**?

Постановка задачи

Домен: поиск недвижимости. AI-агент должен выбрать инструмент по запросу:

GEO → ResolveEntities

Географические сущности: города, районы, метро, адреса

«квартира у метро Сокол»
«снять в центре Москвы»

TAG → SearchTags

Характеристики объекта: площадь, ремонт, этаж, особенности

«квартира с камином»
«студия с панорамными окнами»

Проблема baseline: YandexGPT 5.1 Pro без дообучения показывает accuracy **81.8%** с Macro F1 всего **0.526** --- 59% TAG-запросов обрабатываются некорректно.

Теоретическая основа: Superficial Alignment Hypothesis

LIMA [2] (Meta, 2023): знания LLM формируются при предобучении; alignment **---** *поверхностный слой*. **1000 примеров** достаточно для следования инструкциям.

Наша гипотеза: выбор инструмента **---** тоже поведенческий паттерн:

1. Понимание запроса --- *глубинное знание*
2. Знание об инструментах --- *предобучение* + *контекст*
3. Решение «вызвать или ответить» --- **поведенческий паттерн**
4. Выбор конкретного инструмента --- **поведенческий паттерн**
5. Формирование JSON-вызова --- **формат/стиль**

Пункты 3--5 --- *поверхностное выравнивание*, корректируемое LoRA на малых данных.

Гипотеза исследования

H1: Задача выбора инструмента подчиняется Superficial Alignment Hypothesis --- для её решения достаточно дообучения методом LoRA на **нескольких сотнях** качественных примеров.

Следствия:

- Дообучение даже на **50 примерах** должно дать значимое улучшение над baseline
- Существует **точка насыщения**, после которой наращивание данных не даёт прироста
- **Качество** данных (микс реальных + синтетических) важнее количества

Новизна: связь выводов LIMA с задачей tool selection не исследовалась. Существующие работы [3, 4, 5] не формулировали и не проверяли эту гипотезу.

Метод LoRA

LoRA [1] --- параметрически эффективное дообучение: обновление весов матрицы W:

$$W' = W + \Delta W = W + BA$$

где $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$, $r \ll \min(d, k)$ --- ранг адаптации.

- Дообучается **менее 1%** параметров модели
- Глубинные знания **сохраняются** --- модифицируется поведенческий слой
- Идеально сочетается с гипотезой LIMA: если tool selection --- поверхностный паттерн, LoRA должна эффективно его корректировать

Платформа: YandexGPT 5.1 Lite, дообучение через Yandex Cloud API.

Экспериментальный пайплайн

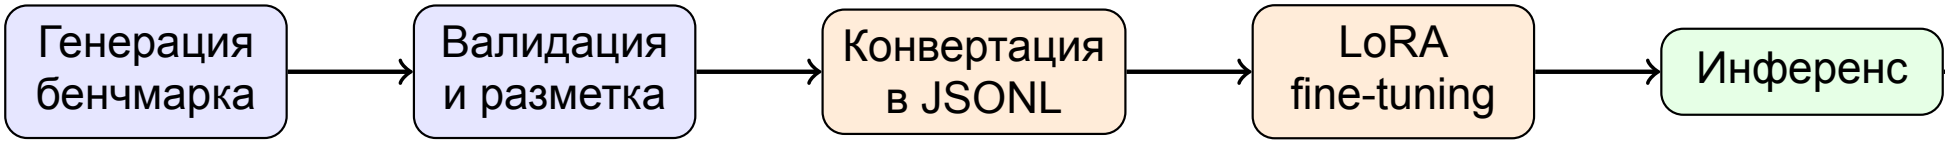

Автоматизация: разработан CLI-инструмент `ml-benchmark` с полным циклом --- от генерации синтетических данных до группового статистического анализа 12 моделей.

Оценка: accuracy, precision, recall, F1, confusion matrix, bootstrap CI (1000 итераций), тесты Кохрена Q и Макнемара с поправкой Бонферрони.

Дизайн эксперимента: обучающие датасеты

Датасет	Тип данных	Объём	GEO : TAG	Humanized
train-synth-50	Синтетические	50	54 : 46	Да
train-synth-250	Синтетические	250	54 : 46	Да
train-synth-500	Синтетические	500	56 : 44	Да
train-synth-1000	Синтетические	908	52 : 48	Да
train-real-250	Реальные	250	82 : 18	Нет
train-mixed-500	**Реал. + синтет.**	**500**	**68 : 32**	**Нет**

Бенчмарки для оценки:

- **benchmark-combined** --- 500 примеров (326 GEO / 174 TAG), реальные + синтетические
- **benchmark-real** --- 250 примеров (203 GEO / 47 TAG), только реальные запросы

Всего обучено и протестировано **12 моделей**: 1 baseline (Pro) + 11 дообученных (Lite).

Baseline: системная проблема

YandexGPT 5.1 Pro без дообучения (benchmark-combined, N=500):

Метрика	Значение
Accuracy	81.8%
Macro F1	**0.526**
Recall GEO	100%
Recall TAG	**49.4%**
Ошибки	57
No prediction	34

Паттерн ошибок:

- 54 из 174 TAG $\rightarrow$ ошибочно GEO
- 34 TAG $\rightarrow$ без tool call
- 198 паразитных вызовов `GetSearchQuerySummary`

Итого: модель некорректно обрабатывает **59%** TAG-запросов.

Вывод: выраженный систематический bias к географическим запросам.

Результаты дообучения: benchmark-combined

Модель	Датасет	Accuracy	Macro F1	Ошибки
pro_baseline	---	81.8%	0.526	57
train_synth_50	Синтет. 50	94.6%	0.631	25
train_synth_250	Синтет. 250	94.6%	0.945	25
train_synth_500	Синтет. 500	97.8%	0.979	9
train_synth_1000	Синтет. 908	95.6%	0.955	20
train_real_250	Реал. 250	95.2%	0.949	22
lite_latest_v2	Синтет. $\sim$1500	98.4%	0.985	6
train_mixed_500	**Микс 500**	**99.4%**	**0.996**	**1**

Ключевое наблюдение: даже 50 синтетических примеров дают скачок с 81.8% до 94.6%. Микс 500 (реальные + синтетические) достигает **99.4%** --- всего **1 ошибка** на 500 примеров.

Кривая насыщения: accuracy vs размер датасета

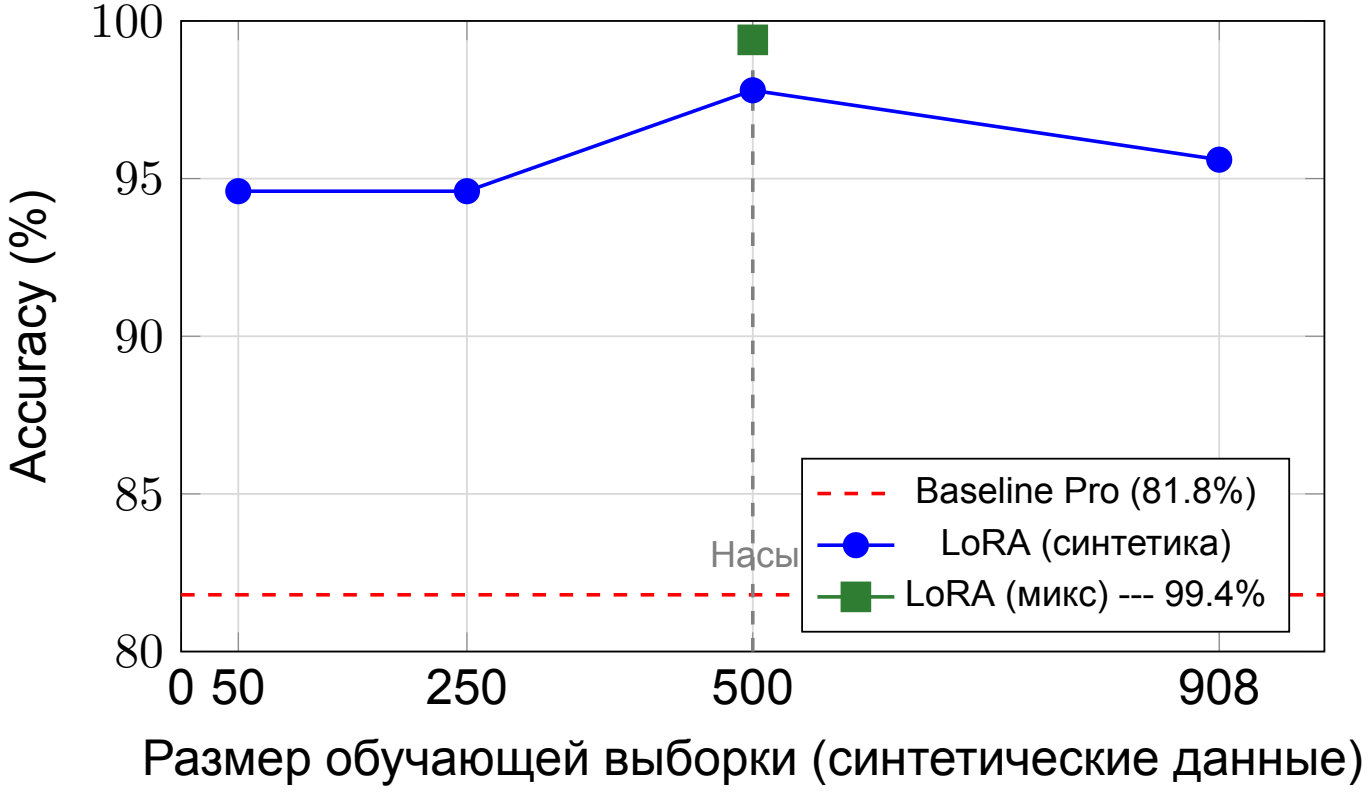

Выводы: пик синтетики --- $\sim$500 примеров; на 908 начинается **деградация** (переобучение). Добавление реальных данных (mixed) даёт качественный скачок.

Качество данных важнее количества

908 синтетических		**500 (250 реал. + 250 синт.)**
Accuracy: 95.6%	$<$	Accuracy: **99.4%**
Macro F1: 0.955		Macro F1: **0.996**

Почему mixed_500 побеждает:

- Синтетика создаёт **обратный bias** --- модель слишком часто выбирает SearchTags
- Реальные данные с bias к GEO --- наоборот
- **Микс балансирует** оба эффекта: GEO$\rightarrow$TAG = 0 ошибок, TAG$\rightarrow$GEO = 1 ошибка

Подтверждение тезиса LIMA: *«quality over quantity»* работает и для tool selection.

Валидация на реальных данных

Все 12 моделей дополнительно проверены на **benchmark-real** (250 реальных запросов):

Модель	Acc (comb.)	Acc (real)	Δ	Ошибки
pro_baseline	81.8%	82.8%	+1.0	28
synth_250	94.6%	89.2%	-5.4	25
synth_500	97.8%	95.6%	-2.2	9
lite_latest_v2	98.4%	96.8%	-1.6	6
real_250	95.2%	**98.0%**	+2.8	3
mixed_500	**99.4%**	**98.8%**	-0.6	**1**

Выводы:

- Синтетические модели **деградируют** на реальных данных (до -5.4 п.п.)
- mixed_500 --- **минимальная деградация** (-0.6 п.п.): стабильно лучший на обоих бенчмарках

Групповой анализ: accuracy с доверительными интервалами

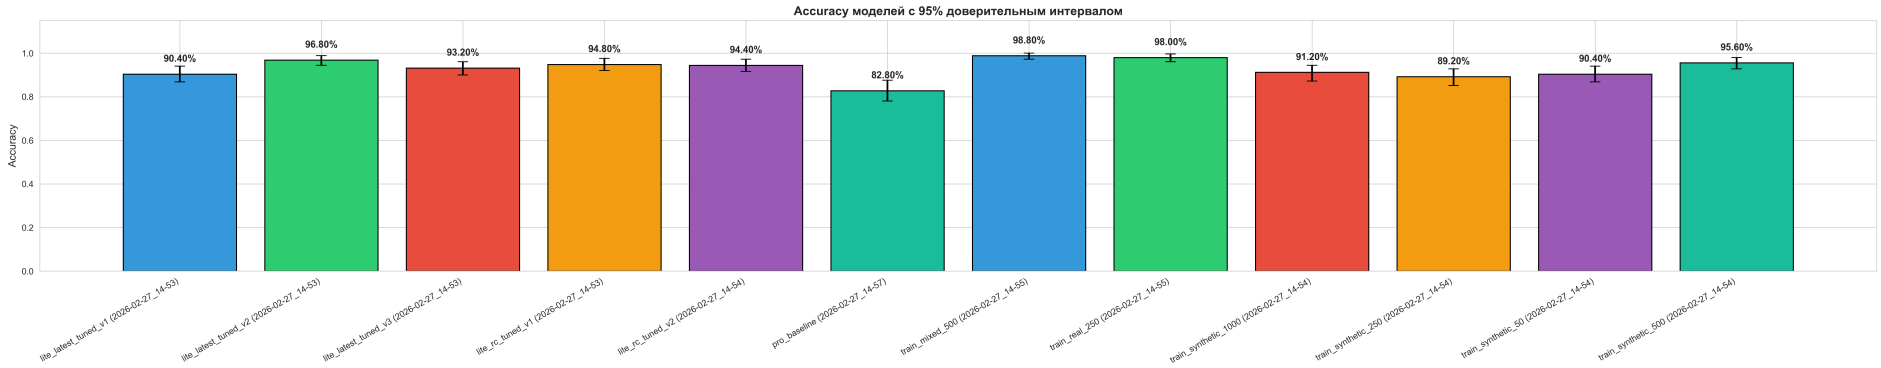

Bootstrap 95% CI (1000 итераций) для каждой из 12 моделей на benchmark-real. **train_mixed_500** и **train_real_250** --- лидеры. Baseline Pro --- аутсайдер (82.8%).

Групповой анализ: все метрики с доверительными интервалами

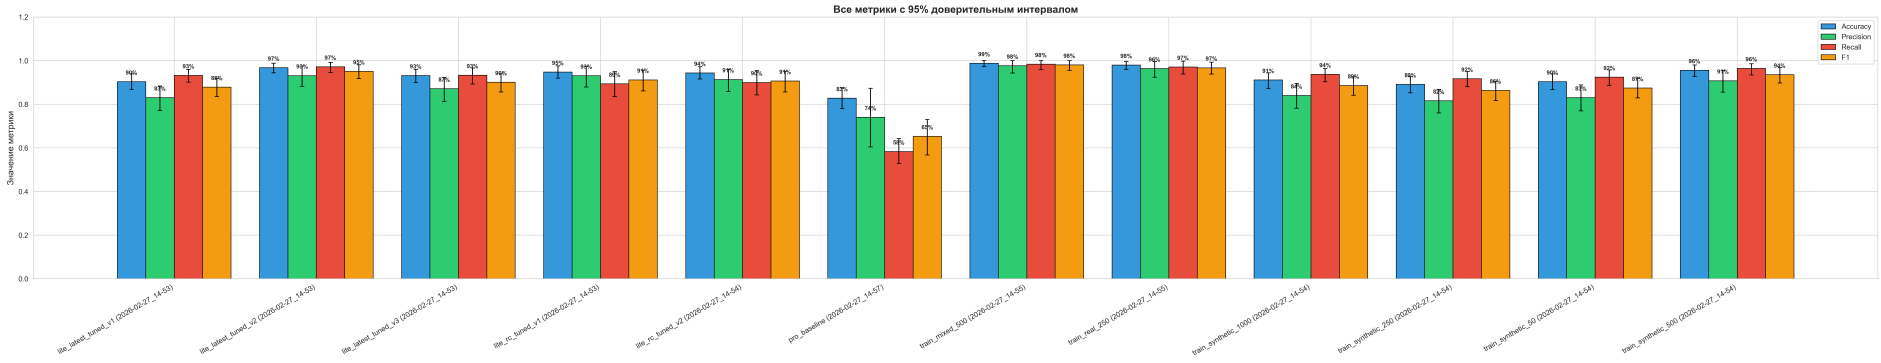

Accuracy, Precision, Recall, F1 --- с 95% bootstrap CI. Видна проблема baseline: **низкий recall** при высоком precision. Дообученные модели выравнивают метрики.

Статистическая значимость: тест Кохрена Q

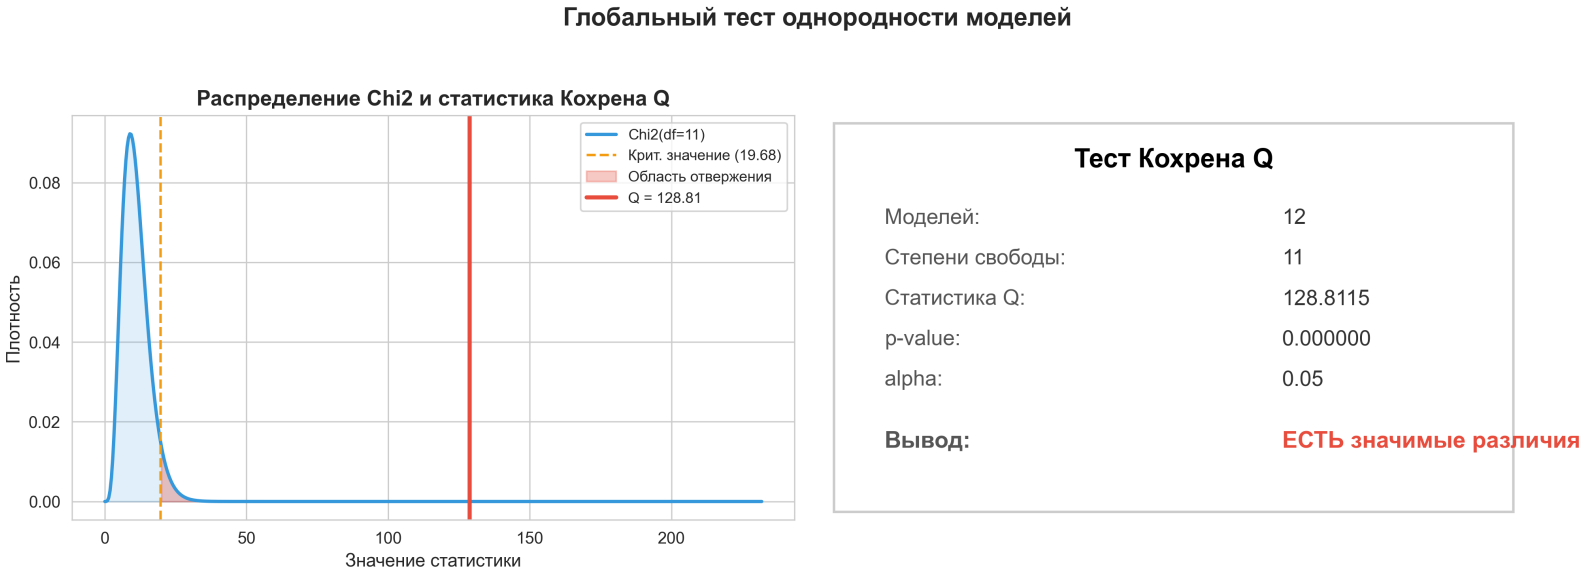

$Q = 128.8$, $p < 0.000001$, $df = 11$ --- различия между 12 моделями **статистически значимы**. H_0 (все модели одинаковы) уверенно отвергается.

Попарные тесты Макнемара

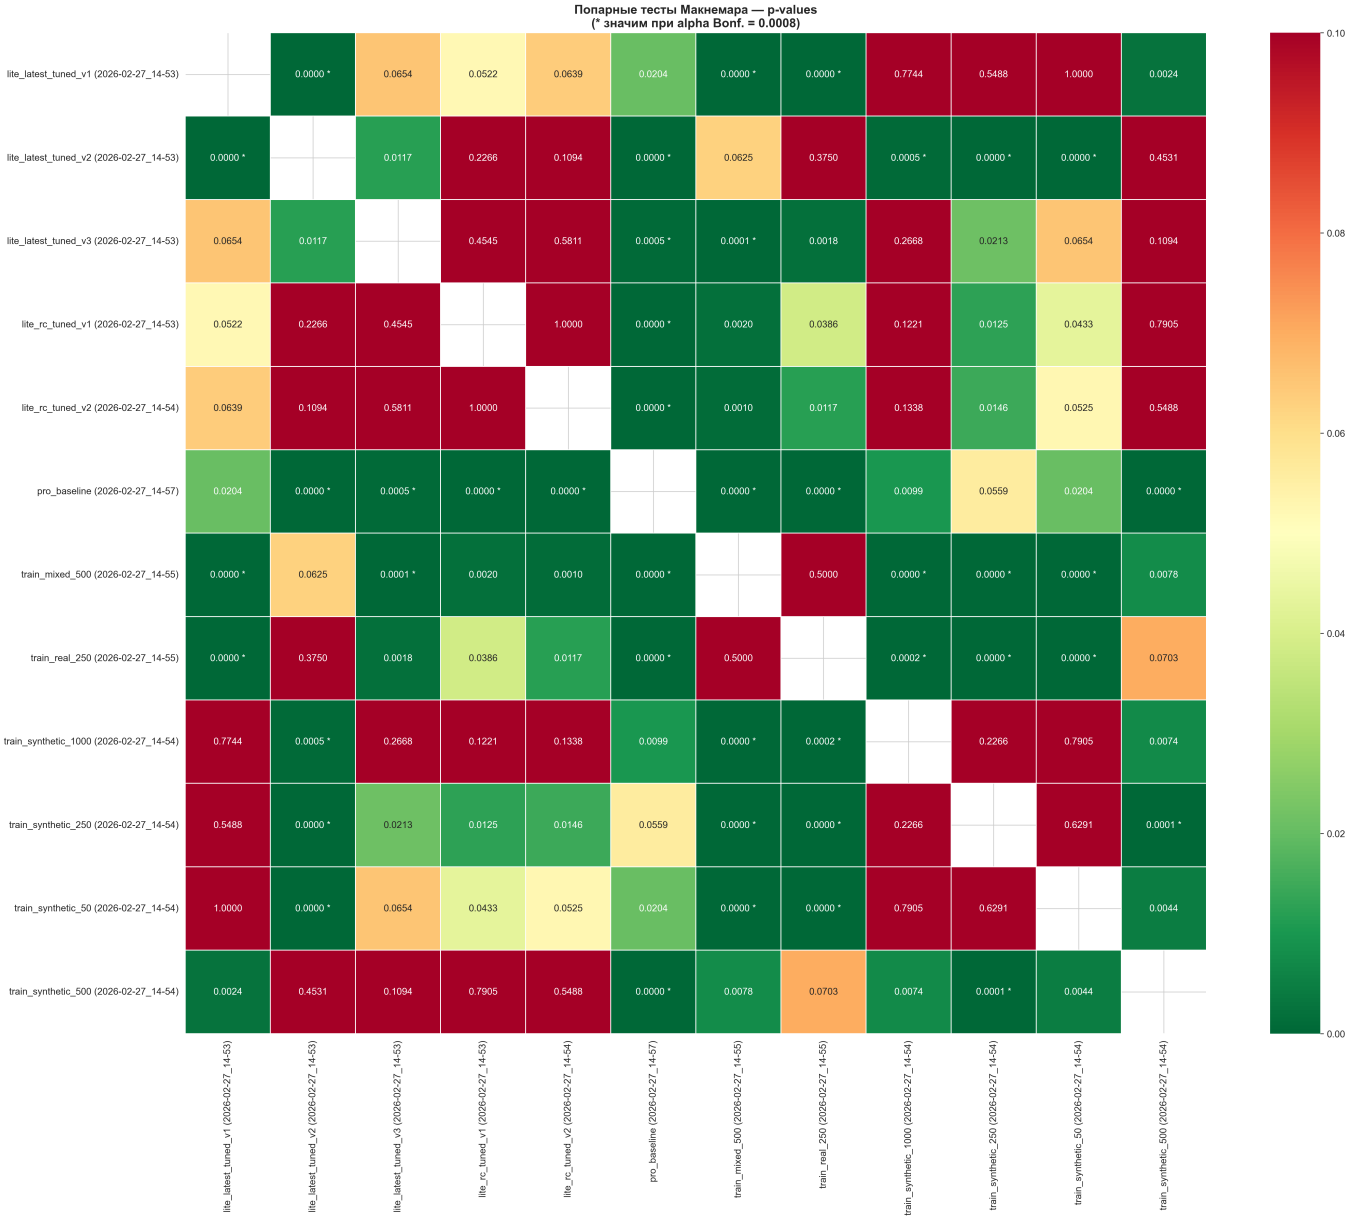

Анализ согласованности и ошибок

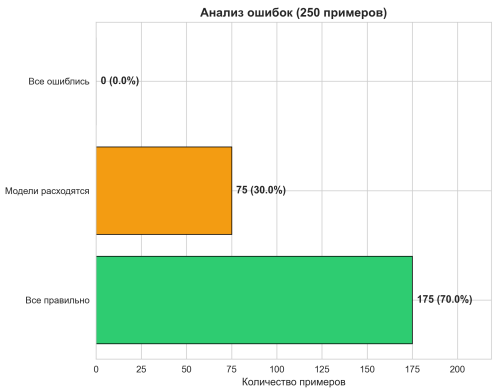

70% примеров --- все 12 моделей верны. **0%** --- ни один пример не ошибочен у всех.

Паттерны ошибок:

Модель	GEO→T	TAG→G
baseline	0	88
synth_*	8--24	1
real_250	1	21
mixed_500	**0**	**1**

Синтетика → обратный bias.
Реальные → прямой bias.
Микс → баланс.

Подтверждение гипотезы

H1 подтверждена: tool selection --- поверхностный паттерн, корректируемый LoRA на малых данных.

Следствие	Ожидание	Результат
Даже 50 примеров дают улучшение	✓	81.8% $\rightarrow$ **94.6%**
Точка насыщения существует	✓	$\sim$500 примеров
Качество $>$ количество	✓	500 микс $>$ 908 синтет.
Статистическая значимость	✓	$Q = 128.8$, $p < 10^{-6}$

Масштаб: accuracy $81.8\% \rightarrow 99.4\%$ ($+17.6$ п.п.), Macro F1 $0.526 \rightarrow 0.996$, ошибки $57 \rightarrow 1$.

Будущие исследования:

- Перенос на другие LLM (GPT-4, Claude, LLaMA)
- Масштабирование на multi-tool selection ($>$2 инструментов)

Заключение

Результаты:

1. Впервые показано, что tool selection подчиняется Superficial Alignment Hypothesis --- это *поведенческий паттерн*, а не глубинное знание
2. LoRA на **500 примерах** (микс) доводит accuracy до **99.4%**
3. Разработан автоматизированный пайплайн с групповым статистическим анализом 12 моделей

Практическая значимость:

- Быстрая интеграция новых инструментов в production AI-агентов **без масштабного сбора данных**
- Формула «250 реальных + 250 синтетических» --- воспроизводимый рецепт для индустрии

Литература I

- Hu E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models // ICLR. --- 2022.
- Zhou Y. et al. LIMA: Less Is More for Alignment // NeurIPS. --- 2023.
- Schick T. et al. Toolformer: Language Models Can Teach Themselves to Use Tools // NeurIPS. --- 2023.
- Patil S. G. et al. Gorilla: Large Language Model Connected with Massive APIs // arXiv:2305.15334. --- 2023.
- Qin Y. et al. ToolLLM: Facilitating Large Language Models to Master 16000+ Real-world APIs // ICLR. --- 2024.

Спасибо за внимание

Выбор инструментов как поверхностное выравнивание:
эффективная адаптация LLM методом LoRA
на минимальных наборах данных

Горошко Андрей Витальевич
СПбГУ, 2026

Дополнительно: ошибки по моделям

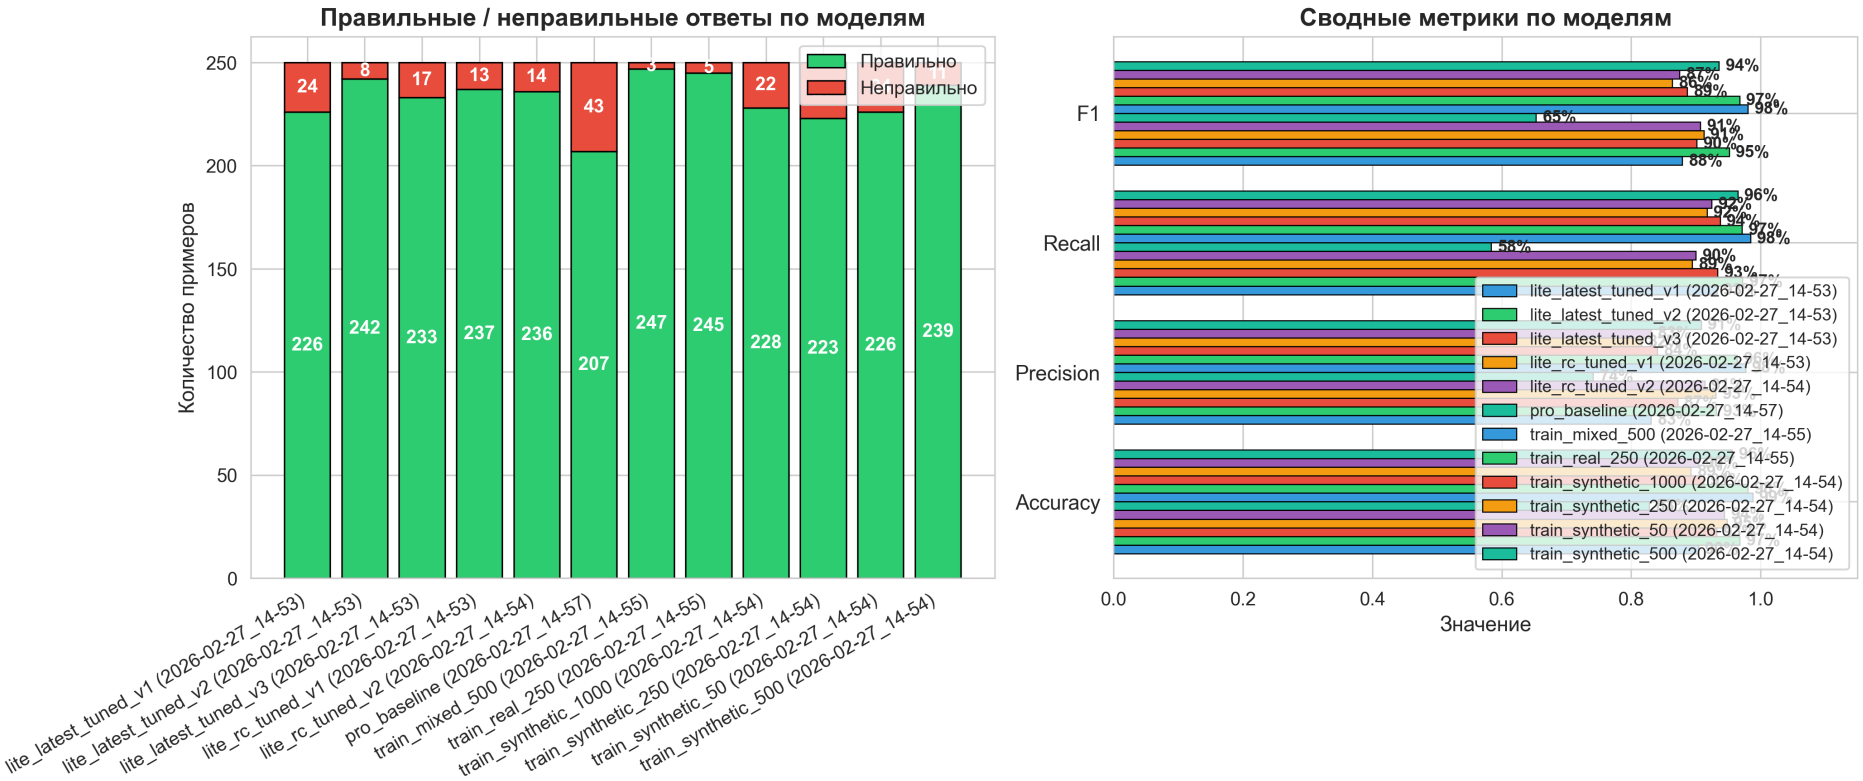

Левая панель: правильные/неправильные ответы по каждой модели. Правая: сводные метрики (accuracy, precision, recall, F1). Pro baseline --- 43 ошибки; mixed_500 --- 3 ошибки.

Дополнительно: разброс при одинаковых данных

Три версии lite_latest (v1/v2/v3), обученные на **одних и тех же** $\sim$1500 синтетических примерах:

Версия	Accuracy	Macro F1	Δ от лучшей
v1	92.8%	0.925	-5.6 п.п.
v2	**98.4%**	**0.985**	**---**
v3	96.6%	0.966	-1.8 п.п.

Разброс **5.6 п.п.** при идентичных данных --- нестабильность процесса дообучения (random seed, порядок данных). Рекомендация: запускать несколько итераций и выбирать лучший результат.

Дополнительно: safety filter и граничные случаи

Safety filter YandexGPT: 2 запроса отклонены **всеми 12 моделями**:

- `q_00159`: «купить однокомнатную в центре Симферополя»
- `q_00253`: «купить квартиру ялта ул красноармейская 13»

Ответ: «Я не могу обсуждать эту тему». Обойти дообучением невозможно.

Спорные разметки: примеры, где 9+ моделей ошибаются:

- `q_00165`: «кладовка от застройщика новый век» (TAG, ошиблись 11/12)
- `q_00046`: «Ищу квартиру поближе к зелёной ветке...» (GEO, 9/12)

Устойчивые пограничные случаи --- объективно содержат признаки обоих классов.

Дополнительно: distribution shift

Синтетические модели **заучивают паттерны генерации**, что приводит к distribution shift:

Модель	Acc (comb.)	Acc (real)	Δ
synth_250	94.6%	89.2%	-5.4 п.п.
synth_1000	95.6%	91.2%	-4.4 п.п.
synth_50	94.6%	90.4%	-4.2 п.п.
synth_500	97.8%	95.6%	-2.2 п.п.
mixed_500	**99.4%**	**98.8%**	-0.6 п.п.
real_250	95.2%	98.0%	$+2.8$ п.п.

Чем больше синтетики при недостаточном разнообразии --- тем сильнее смещение. **Микс реальных и синтетических данных** --- наиболее робастная стратегия.