УДК 004.89

ВЫБОР ИНСТРУМЕНТОВ КАК ПОВЕРХНОСТНОЕ ВЫРАВНИВАНИЕ: ЭФФЕКТИВНАЯ АДАПТАЦИЯ БОЛЬШИХ ЯЗЫКОВЫХ МОДЕЛЕЙ МЕТОДОМ LORA НА МИНИМАЛЬНЫХ НАБОРАХ ДАННЫХ

Горошко А.В. (СПБГУ)

Научный руководитель – кандидат физико-математических наук, ведущий специалист центра ИИ и науки о данных Салищев Сергей Игоревич

(СПБГУ)

Введение. Современные AI-агенты на основе больших языковых моделей (LLM) способны автономно взаимодействовать с внешними сервисами через вызовы инструментов. Критической задачей является корректная маршрутизация пользовательского запроса к соответствующему инструменту. В системах поиска недвижимости это означает различение географических запросов («квартира у метро Сокол») и запросов по характеристикам объекта («квартира с камином»). Существующие исследования демонстрируют возможность обучения LLM выбору инструментов, однако требуют значительных вычислительных ресурсов [1]. Методы параметрически эффективного дообучения, в частности LoRA, позволяют адаптировать менее 1% параметров модели при сохранении качества [2]. Открытым остаётся вопрос минимально достаточного объёма данных для такой адаптации

Основная часть. В работе исследуется гипотеза о том, что задача выбора инструмента является «поверхностной» относительно базовых знаний LLM и может быть решена дообучением на минимальных наборах данных. Для проверки гипотезы разработан экспериментальный пайплайн, включающий генерацию синтетического бенчмарка, автоматическую разметку ground truth, инференс модели и комплексную оценку качества.

Эксперименты проводились на модели YandexGPT 5.1 с использованием метода LoRA через Yandex Cloud API. Базовая модель показала точность классификации инструментов 68,28% с выраженным систематическим смещением: 100% полнота для географических запросов при 41% полноте для теговых запросов. Анализ матрицы ошибок выявил, что 45% теговых запросов ошибочно классифицируются как географические.

Дообучение проводилось на наборах данных различного объёма. Для статистического обоснования результатов применялись бутстрап-оценки доверительных интервалов, тест Кохрена Q для общего сравнения обучающих наборов, попарные тесты Макнемара с поправкой на множественные сравнения. Построены кривые насыщения качества модели в зависимости от объёма обучающей выборки.

Результаты подтверждают статистическую значимость улучшений: дообученные модели превосходят базовую по точности классификации. Выявлен оптимальный объём данных, после которого прирост качества становится несущественным, что подтверждает гипотезу о поверхностном характере выравнивания для задачи выбора инструментов.

Выводы. Исследование демонстрирует эффективность метода LoRA для адаптации LLM к задаче классификации инструментов на минимальных наборах данных. Практическая значимость работы заключается в возможности быстрой интеграции новых инструментов в production-системы AI-агентов без масштабного сбора данных.

Список использованных источников:

1. Schick T., Dwivedi-Yu J., Dessì R. et al. Toolformer: Language Models Can Teach Themselves to Use Tools // Advances in Neural Information Processing Systems. — 2023.
2. Hu E.J., Shen Y., Wallis P. et al. LoRA: Low-Rank Adaptation of Large Language Models // International Conference on Learning Representations. — 2022.

Автор: _____ Горошко А.В.

Научный руководитель: _____ Салищев С.И.