Санкт-Петербургский государственный университет

Методы ресемплирования

Горошко Андрей, группа 22.Б13

Кросс-валидация

Кросс-валидация --- это метод ресемплирования, при котором различные подмножества данных поочерёдно используются для обучения и проверки статистической модели.

Кросс-валидация

Кросс-валидация --- это метод ресемплирования, при котором различные подмножества данных поочерёдно используются для обучения и проверки статистической модели.

$T = \{x_i, y_i\}_{i=1}^{n}$ --- набор наблюдений

x_i --- вектор признаков i-го объекта

y_i --- целевое значение i-го объекта

Валидация отложенной выборкой

Простейший способ оценки качества модели --- случайное разделение набора данных на две непересекающиеся части: обучающую и валидационную выборки.

Валидация отложенной выборкой

Простейший способ оценки качества модели --- случайное разделение набора данных на две непересекающиеся части: обучающую и валидационную выборки.

- Выберем натуральное число t: $t \leq n$
- Случайным образом разобьём множество наблюдений на две части:

$$T = T^t \cup T^{n-t}, \quad |T^t| = t, \quad |T^{n-t}| = n - t$$

Валидация отложенной выборкой

Набор данных Auto: нелинейная зависимость между расходом топлива (mpg) и мощностью двигателя (horsepower). Могут ли полиномы степени выше 2 дать лучший результат?

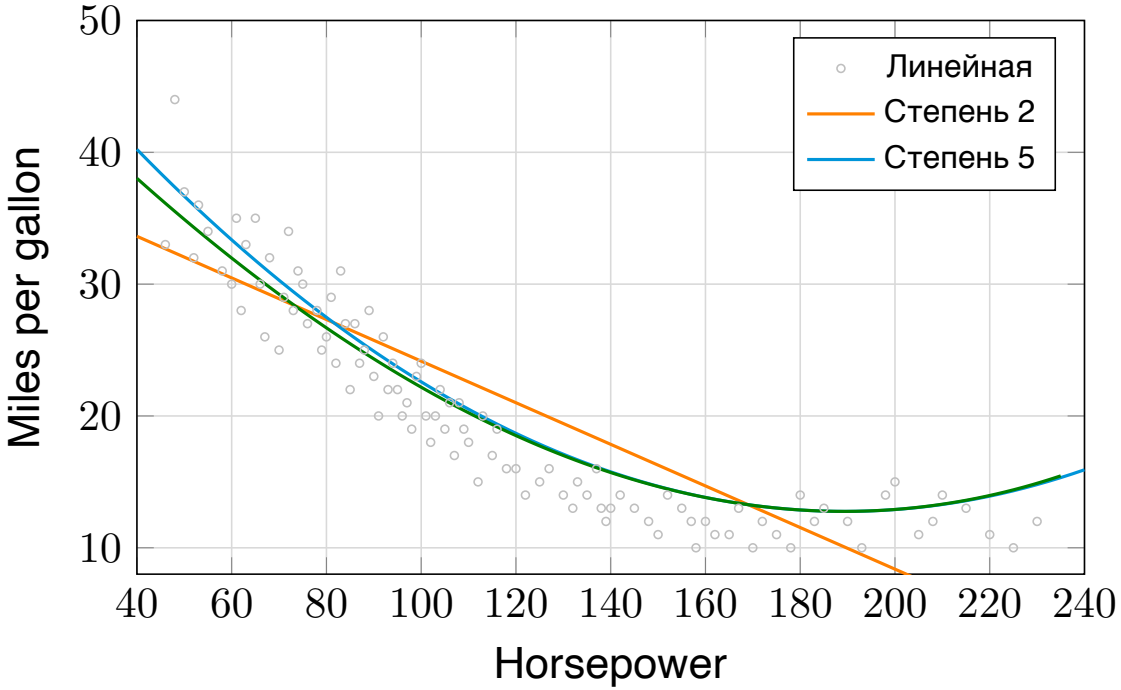

Валидация отложенной выборкой

Включение полиномов степени выше 2 практически не улучшает результат.

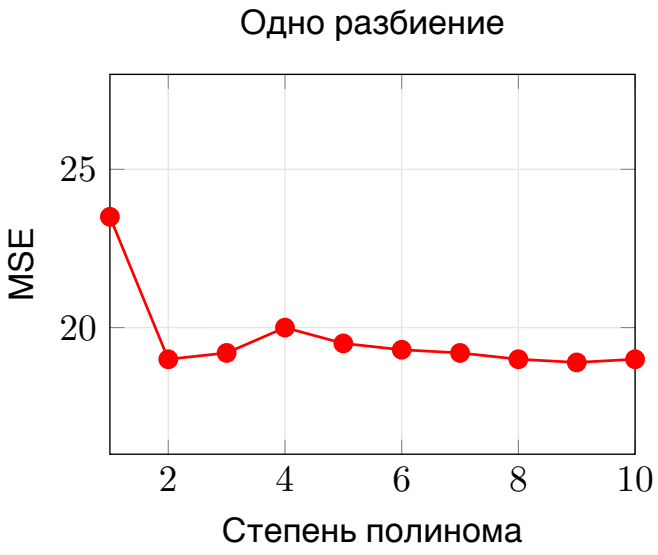

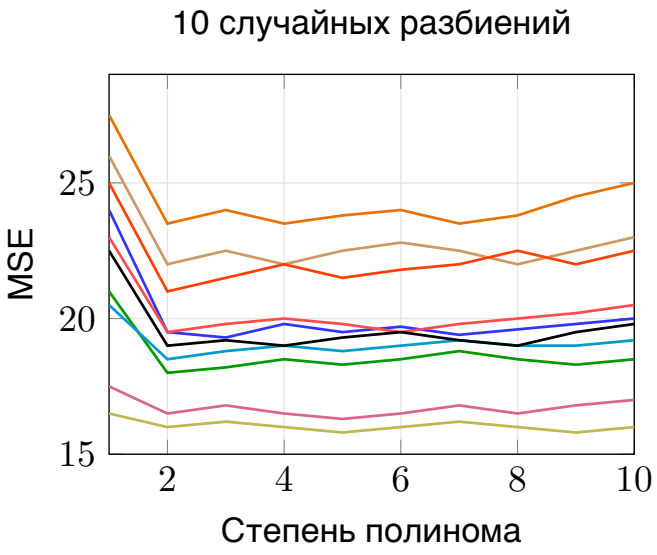

Валидация отложенной выборкой: недостатки

Несмотря на простоту реализации, у метода есть существенные ограничения:

- Оценка ошибки может **сильно варьироваться** в зависимости от того, какие именно наблюдения попали в обучающую выборку, а какие --- в валидационную.

Валидация отложенной выборкой: недостатки

Несмотря на простоту реализации, у метода есть существенные ограничения:

- Оценка ошибки может **сильно варьироваться** в зависимости от того, какие именно наблюдения попали в обучающую выборку, а какие --- в валидационную.
- Для обучения модели используется лишь часть данных --- наблюдения из валидационной выборки никак не участвуют в подборе параметров.

Кросс-валидация с исключением одного (LOOCV)

Одно наблюдение (x_1, y_1) выделяется для проверки, а оставшиеся $\{(x_2, y_2), \ldots, (x_n, y_n)\}$ формируют обучающую выборку.

Кросс-валидация с исключением одного (LOOCV)

Одно наблюдение (x_1, y_1) выделяется для проверки, а оставшиеся $\{(x_2, y_2), \ldots, (x_n, y_n)\}$ формируют обучающую выборку.

Модель обучается на $n - 1$ наблюдениях, после чего строится прогноз $\hat{y}_1$ для исключённого объекта.

Кросс-валидация с исключением одного (LOOCV)

Одно наблюдение (x_1, y_1) выделяется для проверки, а оставшиеся $\{(x_2, y_2), \ldots, (x_n, y_n)\}$ формируют обучающую выборку.

Модель обучается на $n - 1$ наблюдениях, после чего строится прогноз $\hat{y}_1$ для исключённого объекта.

$MSE_1 = (y_1 - \hat{y}_1)^2$ даёт приближённо несмещённую оценку ошибки на тесте. Однако она обладает **высокой дисперсией**!

LOOCV: повторение процедуры

Процедуру можно повторить, выбрав (x_i, y_i) в качестве валидационного наблюдения, обучив модель на остальных $n-1$ объектах $\{(x_1, y_1), \ldots, (x_{i-1}, y_{i-1}), (x_{i+1}, y_{i+1}), \ldots, (x_n, y_n)\}$ и вычислив MSE_i.

LOOCV: повторение процедуры

Процедуру можно повторить, выбрав (x_i, y_i) в качестве валидационного наблюдения, обучив модель на остальных $n-1$ объектах $\{(x_1, y_1), \ldots, (x_{i-1}, y_{i-1}), (x_{i+1}, y_{i+1}), \ldots, (x_n, y_n)\}$ и вычислив MSE_i.

Повторив эту операцию n раз, вычислим оценку LOOCV тестовой MSE:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^{n} MSE_i$$

LOOCV: достоинства

Преимущества LOOCV:

- Метод обладает **малым смещением**. На каждой итерации модель обучается на $n - 1$ объектах --- почти на всей выборке целиком.

LOOCV: достоинства

Преимущества LOOCV:

- Метод обладает **малым смещением**. На каждой итерации модель обучается на $n-1$ объектах --- почти на всей выборке целиком.
- В отличие от валидации отложенной выборкой, которая даёт разные результаты при повторном применении из-за случайности разбиения, LOOCV при многократном запуске всегда даёт один и тот же результат: **случайность в разбиении отсутствует**.

LOOCV: достоинства и недостатки

Преимущества LOOCV:

- Метод обладает **малым смещением**. На каждой итерации модель обучается на $n-1$ объектах --- почти на всей выборке целиком.
- LOOCV при многократном запуске всегда даёт один и тот же результат: **случайность в разбиении отсутствует**.

Недостаток:

- Метод может быть **вычислительно дорогим**: модель необходимо обучить n раз. При большом n или при медленном обучении отдельной модели это занимает значительное время.

K-блочная кросс-валидация

Данный подход предполагает случайное разделение набора наблюдений на k групп (блоков, или фолдов) приблизительно одинакового размера. Первый блок выступает в роли валидационной выборки, а модель обучается на оставшихся $k-1$ блоках.

K-блочная кросс-валидация

Данный подход предполагает случайное разделение набора наблюдений на k групп приблизительно одинакового размера. Первый блок выступает в роли валидационной выборки, а модель обучается на оставшихся $k-1$ блоках.

Средняя квадратичная ошибка MSE_1 вычисляется по наблюдениям из отложенного блока. Процедура повторяется k раз; каждый раз валидационным становится другой блок.

K-блочная кросс-валидация

Данный подход предполагает случайное разделение набора наблюдений на k групп приблизительно одинакового размера. Первый блок --- валидационная выборка, модель обучается на оставшихся $k-1$ блоках.

MSE_1 вычисляется по наблюдениям из отложенного блока. Процедура повторяется k раз.

Оценка ошибки при k-блочной кросс-валидации:

$$CV_{(k)} = \frac{1}{k}\sum_{i=1}^{k} MSE_i$$

K-блочная кросс-валидация: схема

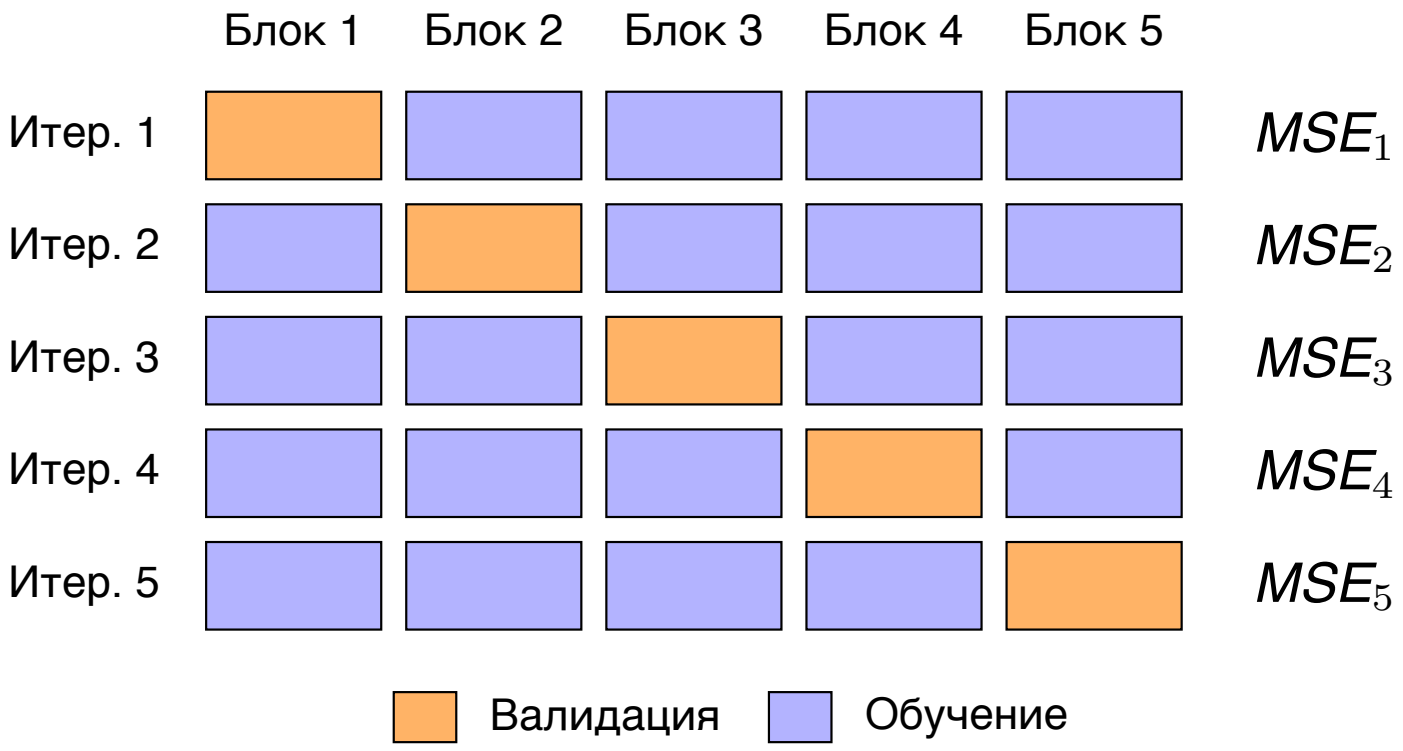

K-блочная кросс-валидация

Возвращаясь к набору данных Auto: при 10-блочной кросс-валидации разброс оценок ошибки значительно ниже по сравнению с валидацией отложенной выборкой.

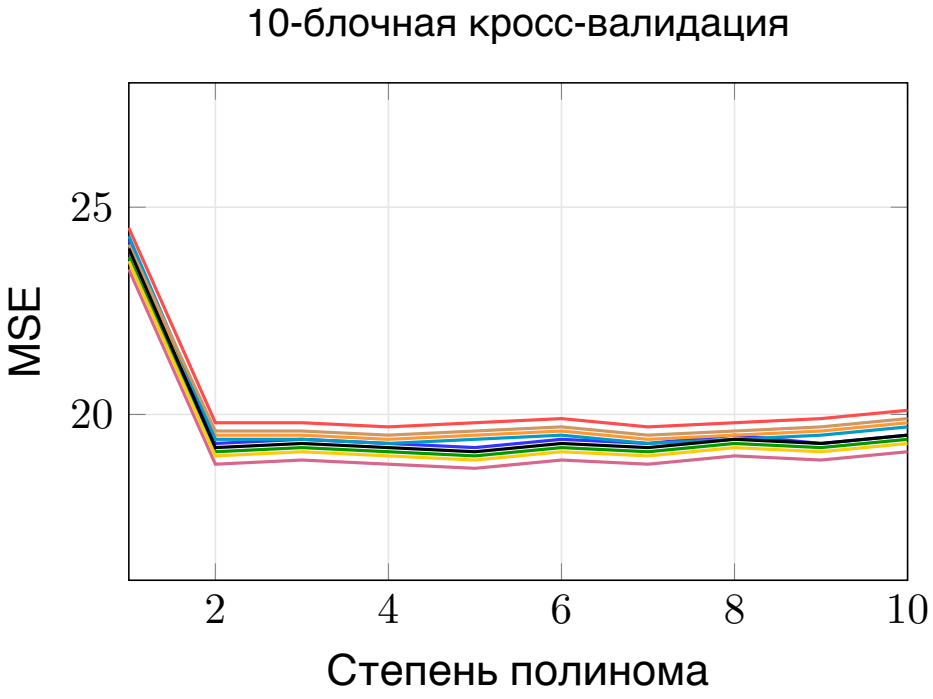

K-блочная кросс-валидация

Оценки кросс-валидации для смоделированных данных. Синяя --- обучающая MSE, оранжевая --- тестовая MSE, - - - пунктир --- оценка CV.

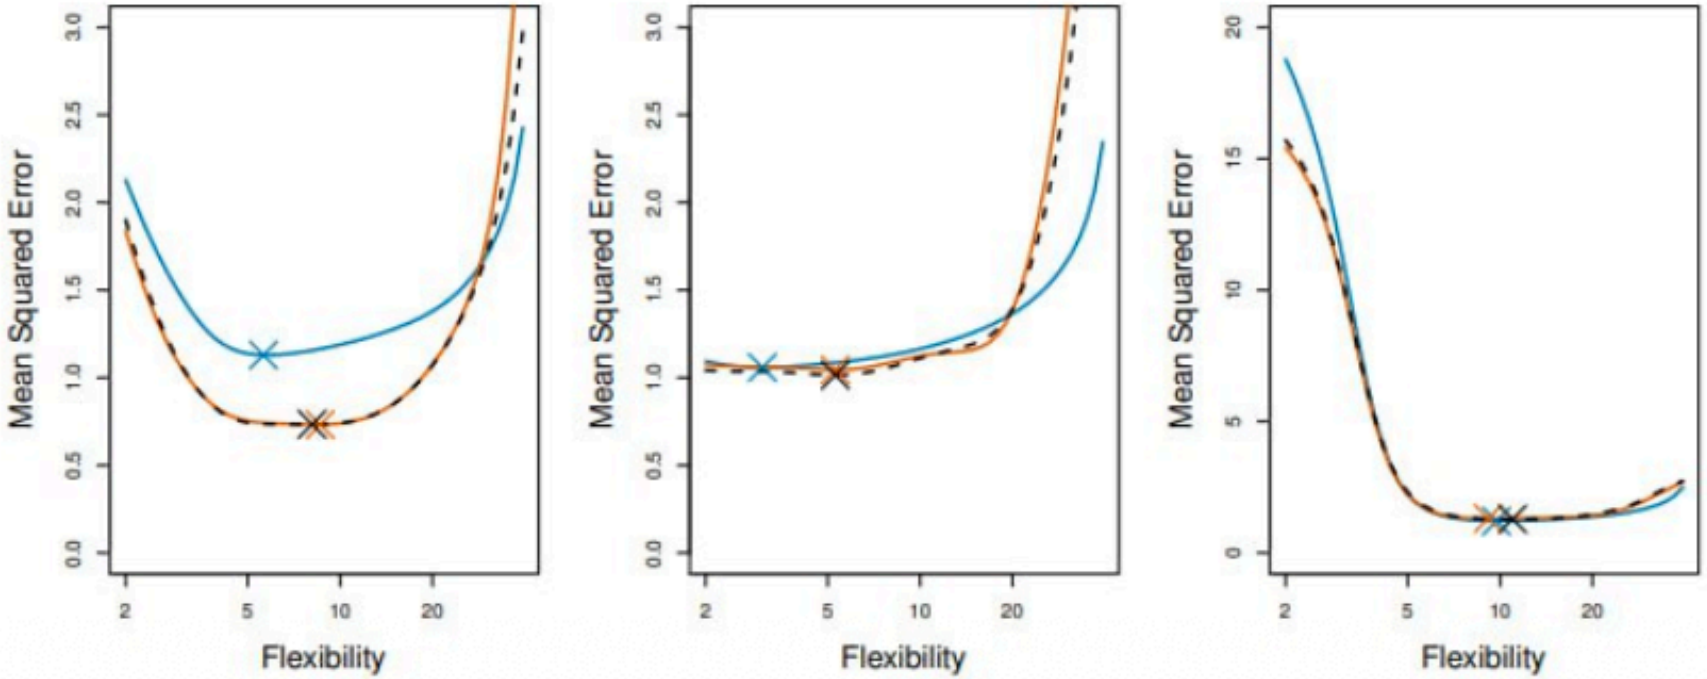

K-блочная кросс-валидация: цель

Основная цель кросс-валидации --- определить, насколько хорошо выбранная статистическая модель будет работать на независимых данных.

Нас интересует прежде всего **положение минимума** на кривой оценки тестовой MSE, а не само точное значение ошибки. Это связано с тем, что кросс-валидацию часто применяют для сравнения нескольких моделей или для выбора уровня гибкости одной модели, чтобы найти вариант с наименьшей тестовой ошибкой.

K-блочная кросс-валидация: компромисс смещение--дисперсия

Помимо вычислительного преимущества перед LOOCV, k-блочная кросс-валидация зачастую даёт **более точные** оценки тестовой ошибки. Причина кроется в компромиссе между смещением и дисперсией.

K-блочная кросс-валидация: компромисс смещение--дисперсия

Помимо вычислительного преимущества перед LOOCV, k-блочная кросс-валидация зачастую даёт **более точные** оценки тестовой ошибки.

K-блочная кросс-валидация занимает промежуточное положение по смещению: оно выше, чем у LOOCV, но ниже, чем у валидации отложенной выборкой.

K-блочная кросс-валидация: компромисс смещение--дисперсия

Помимо вычислительного преимущества перед LOOCV, k-блочная кросс-валидация зачастую даёт **более точные** оценки тестовой ошибки.

K-блочная CV занимает промежуточное положение по смещению: оно выше, чем у LOOCV, но ниже, чем у валидации отложенной выборкой.

Однако необходимо учитывать и дисперсию процедуры. У LOOCV дисперсия **выше**, чем у k-блочной CV. При LOOCV мы усредняем результаты n моделей, каждая из которых обучена на почти идентичном множестве данных; следовательно, эти результаты **сильно коррелированы**. Среднее большого числа сильно коррелированных величин обладает более высокой дисперсией.

Бутстрэп

Бутстрэп --- это мощный инструмент для количественной оценки неопределённости заданной статистической оценки или метода машинного обучения.

Бутстрэп

Бутстрэп --- это мощный инструмент для количественной оценки неопределённости заданной статистической оценки или метода машинного обучения.

Предположим, мы хотим вложить фиксированную сумму в два финансовых актива, доходности которых --- случайные величины X и Y. Долю α вкладываем в X, а оставшуюся часть $(1-\alpha)$ --- в Y.

Бутстрэп

Бутстрэп --- это мощный инструмент для количественной оценки неопределённости заданной статистической оценки или метода машинного обучения.

Предположим, мы хотим вложить фиксированную сумму в два финансовых актива, доходности которых --- случайные величины X и Y. Долю α вкладываем в X, а оставшуюся часть $(1-\alpha)$ --- в Y.

Наша задача --- подобрать α так, чтобы минимизировать суммарный риск, то есть дисперсию портфеля.

Бутстрэп: оптимальное α

Другими словами, мы хотим минимизировать $\mathrm{Var}(\alpha X + (1-\alpha) Y)$

Бутстрэп: оптимальное α

Другими словами, мы хотим минимизировать $\mathrm{Var}(\alpha X + (1-\alpha) Y)$

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}$$

Бутстрэп: оптимальное α

Другими словами, мы хотим минимизировать $\mathrm{Var}(\alpha X + (1-\alpha) Y)$

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}$$

На практике значения σ_X^2, σ_Y^2 и σ_{XY} неизвестны. Мы можем вычислить их оценки: $\hat{\sigma}_X^2$, $\hat{\sigma}_Y^2$ и $\hat{\sigma}_{XY}$

Бутстрэп: оценка α

Тогда оценка значения α:

$$\hat{\alpha} = \frac{\hat{\sigma}_Y^2 - \hat{\sigma}_{XY}}{\hat{\sigma}_X^2 + \hat{\sigma}_Y^2 - 2\hat{\sigma}_{XY}}$$

Бутстрэп: оценивание α на симуляции

Для оценки α мы можем смоделировать 100 пар доходностей инвестиций X и Y. По ним вычисляются оценки σ_X^2, σ_Y^2 и σ_{XY}, а затем --- оценка α.

Естественно оценить стандартное отклонение $\hat{\alpha}$.

Бутстрэп: оценивание α на симуляции

Для оценки α смоделируем 100 пар доходностей X и Y, вычислим оценку α.
Повторив процедуру 1000 раз, усредним результат.

$$\bar{\alpha} = \frac{1}{1000} \sum_{r=1}^{1000} \hat{\alpha}_r = 0.5996$$

При истинных характеристиках данных: $\sigma_X^2 = 1$, $\sigma_Y^2 = 1.25$, $\sigma_{XY} = 0.5$ и $\alpha = 0.6$

Бутстрэп: распределение оценок

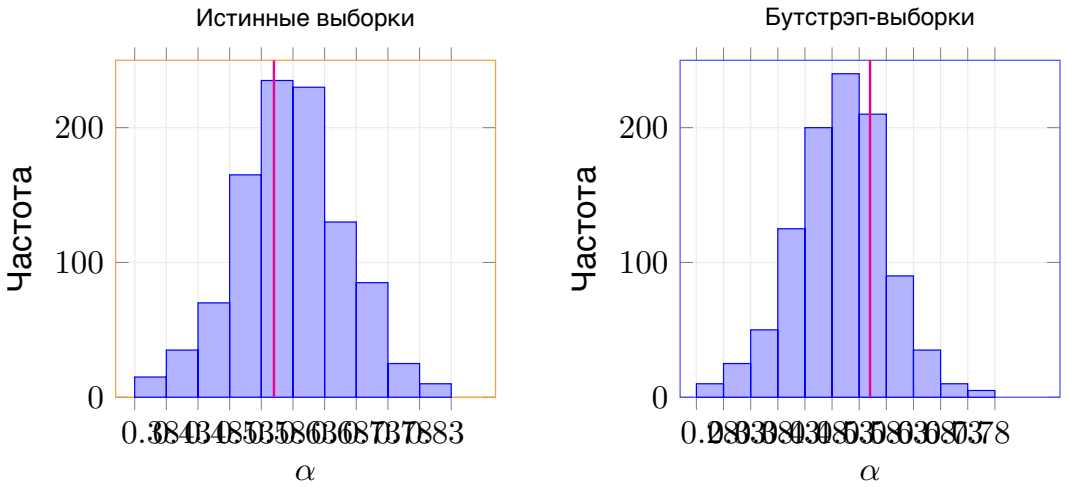

Розовая линия --- истинное значение $\alpha = 0.6$

Бутстрэп: основная идея

На практике мы не можем генерировать новые выборки из исходной генеральной совокупности. Однако метод бутстрэпа позволяет нам использовать компьютер для имитации процесса получения новых наборов данных, чтобы оценить вариабельность $\hat{\alpha}$ без дополнительных выборок.

Вместо многократного извлечения независимых наборов из генеральной совокупности мы формируем различные наборы путём **повторной выборки с возвращением** из имеющихся данных.

Бутстрэп: схема

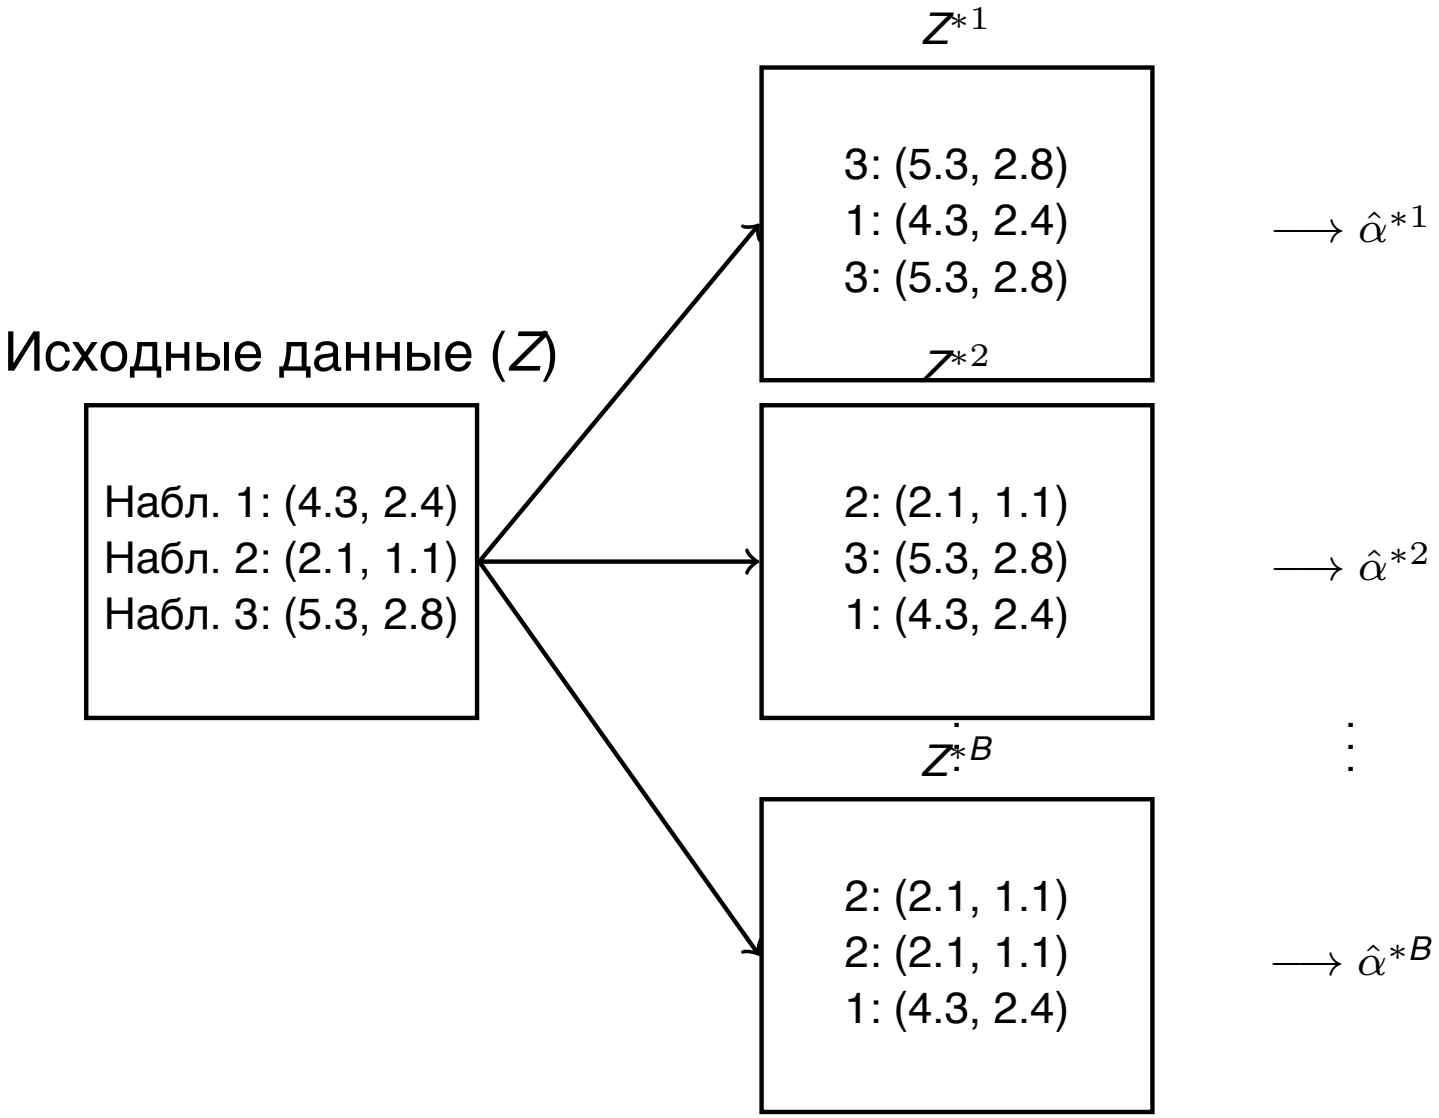

Бутстрэп: процедура

Рассмотрим набор из $n = 3$ наблюдений. Из исходных данных случайным образом извлекаем n наблюдений **с возвращением**, формируя бутстрэп-выборку Z^{*1}. Так как выборка производится с возвращением, одно и то же наблюдение может встретиться несколько раз.

По Z^{*1} вычисляем новую оценку $\hat{\alpha}^{*1}$. Процедура повторяется B раз, что даёт B различных бутстрэп-выборок $Z^{*1}, Z^{*2}, \ldots, Z^{*B}$ и B соответствующих оценок $\hat{\alpha}^{*1}, \hat{\alpha}^{*2}, \ldots, \hat{\alpha}^{*B}$.

Бутстрэп: стандартная ошибка

По B бутстрэп-оценкам $\hat{\alpha}^{*1}, \hat{\alpha}^{*2}, \ldots, \hat{\alpha}^{*B}$ можно вычислить стандартную ошибку:

$$SE_B(\hat{\alpha}) = \sqrt{\frac{1}{B-1}\sum_{r=1}^{B}\left(\hat{\alpha}^{*r} - \frac{1}{B}\sum_{r'=1}^{B}\hat{\alpha}^{*r'}\right)^2}$$

Итоги

- **Валидация отложенной выборкой**: просто, но с высокой дисперсией оценки и неэффективным использованием данных
- **LOOCV**: малое смещение, детерминированный результат, однако вычислительно затратный и может обладать высокой дисперсией
- **K-блочная кросс-валидация**: практичный компромисс между смещением и дисперсией; обычно используют $k = 5$ или $k = 10$
- **Бутстрэп**: универсальный инструмент для оценки неопределённости через повторную выборку с возвращением