Санкт-Петербургский государственный университет
Кафедра математики и компьютерных наук
02.03.01 «Математика и компьютерные науки», СВ.5001.2022

Анализ влияния дообучения YandexGPT на корректность выбора функции для получения данных по исходному запросу

Горошко Андрей Витальевич, группа 22.Б13-мм

2026

Научный руководитель: доц. Григорьева А. В.

Рецензент: ст. преп. Севостьянов Р. А., к. ф.-м. н.

Санкт-Петербург, 2026

Контекст: AI-агенты и tool use

- LLM — ядро современного AI-агента
- *Function calling*: модель сама решает, какую функцию вызвать
- Прикладная задача — AI-агент в домене недвижимости
- Два инструмента:
  - `ResolveEntities` (GEO) — города, станции, адреса
  - `SearchTags` (TAG) — характеристики объекта

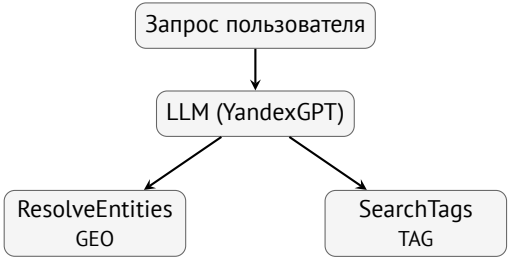

Ключевое разграничение:
«у метро Сокол» = GEO
«у метро» = TAG (категория транспортной доступности)

Проблема: baseline неприменим в production

YandexGPT 5.1 Pro *без дообучения* на benchmark-combined (500 запросов):

- Accuracy $= 81{,}8\%$
- Macro $F_1 = 0{,}526$
- Recall класса TAG $= 49{,}4\%$
- Без `tool_call`: $\rho_{\varnothing} = 6{,}8\%$ (34 запроса)

Систематический bias к GEO:
все 57 ошибок одного типа $\mathrm{TAG} \to \mathrm{GEO}$, ни одной обратной.

Пример ошибки baseline:

> *«квартира с панорамными окнами и видом на парк»*

Истинно: `SearchTags` (TAG)
Предсказание: `ResolveEntities` (GEO)
Эффект: агент ищет несуществующий «парк»-топоним, вместо фильтра по характеристике.

Цель и задачи

Цель: экспериментально проверить, что LoRA-дообучение значимо улучшает корректность выбора функции в AI-агенте.

Задачи:

1. Формализовать выбор инструмента как бинарную классификацию; собрать два независимых бенчмарка (combined и real).
2. Разработать воспроизводимый пайплайн дообучения и оценки (CLI `ml-benchmark`).
3. Обучить и оценить 12 конфигураций моделей с вариацией типа и объёма обучающих данных.
4. Применить строгий статистический анализ (Cochran Q, McNemar, bootstrap).

Формальная постановка

Классификатор первого `tool_call`:

$$f_\theta \colon \mathcal{X} \to \{t_{\mathrm{GEO}},\ t_{\mathrm{TAG}}\}.$$

Ошибки:

- *I рода:* $\mathrm{TAG} \to \mathrm{GEO}$
  агент ищет несуществующий гео-объект.
- *II рода:* $\mathrm{GEO} \to \mathrm{TAG}$
  теряется географическая привязка.
- Третий исход: $\rho_\varnothing$ — модель не сгенерировала вызов инструмента.

Реальные примеры:

- GEO: «снять квартиру в центре Казани на месяц»
- TAG: «квартира с панорамными окнами и видом на парк»
- Спорный (TAG): «возле зелёной ветки» (жаргон)

Гипотезы и критерии успеха

H1a (значимость). Дообучение значимо снижает долю ошибок относительно baseline.
Тест: односторонний McNemar, $\alpha = 0{,}05$.

H1b (порог). Нижняя граница 95 % bootstrap-CI accuracy лучшей модели $> 0{,}9$.

H2 (качество $>$ объём). Сбалансированный микс реальных и синтетических данных превосходит чистую синтетику при равном или большем объёме.

Метрика	Baseline	Цель	Бенчмарк
Accuracy	$81{,}8\%$	$> 90\%$	combined
Macro F_1	$0{,}526$	$> 0{,}85$	combined
Recall (t_{TAG})	$49{,}4\%$	$> 75\%$	combined
$\rho_{\varnothing}$	$6{,}8\%$	$< 3\%$	combined

Гипотеза поверхностного выравнивания (SAH)

LIMA, Zhou et al. (2023):

> *Knowledge is learnt during pretraining; alignment teaches the model which subdistribution of formats to use.*

Аналогия для tool selection:
выбор функции — устойчивый *паттерн формы ответа*, а не семантическое знание. Соответственно, небольшого набора качественных примеров достаточно для радикального улучшения.

Положение в литературе

Дообучение:

- LoRA — Hu et al., 2022
- PEFT — Ding et al., 2023

Tool use:

- Toolformer — Schick et al., 2023
- Gorilla — Patil et al., 2023
- Tool Learning — Qin et al., 2024

Бенчмарки:

- BFCL — Berkeley Function Calling Leaderboard
- ToolBench, API-Bank

Где gap:

- Существующие работы — англоязычные открытые модели.
- Нет систематического исследования *коммерческой русскоязычной* LLM на узком домене.
- Нет строгого статпротокола (Cochran Q + McNemar + bootstrap) для tool-selection.

Выбор YandexGPT:
модель используется в production исследуемого AI-агента; сравнение с GigaChat / Saiga / ruGPT — направление дальнейшей работы.

Пайплайн эксперимента

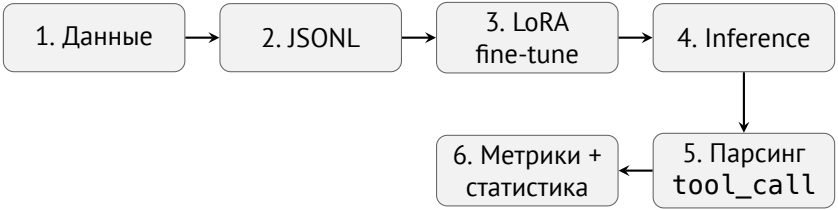

Ключевые инженерные решения:

- CLI `ml-benchmark` автоматизирует все шесть этапов
- Чекпоинтинг: восстановление с последнего обработанного запроса
- Retry на временные ошибки API (rate limits, 5xx)
- Парсинг первого `<tool_call>` из XML-ответа модели

Бенчмарки и примеры запросов

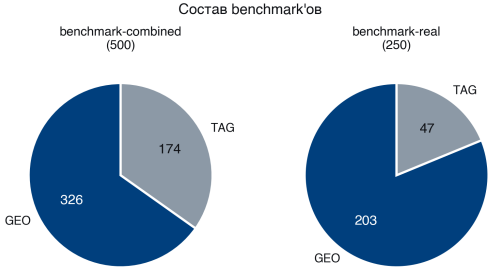

Реальные примеры из логов агента:

- *GEO:* «снять квартиру в центре Казани на месяц»
- *GEO:* «у метро Сокол двушку»
- *TAG:* «квартира с панорамными окнами и видом на парк»
- *TAG:* «у метро» (категория, без имени)

Контроль утечек:

500 реальных запросов разделены 50/50 между `benchmark-real` и `train-real-250`.

Пересечение по нормализованному тексту $= \varnothing$.

Обучающие датасеты

Обучающие выборки

Выборка	Примеров	Тип данных
train-synthetic-50	50	synthetic
train-synthetic-250	250	synthetic
train-synthetic-500	500	synthetic
train-synthetic-1000	908	synthetic
train-real-250	250	real
train-mixed-500	500	mixed (250r + 250s)

6 основных конфигураций:

- `synth-50/250/500/908`
- `real-250`
- `mixed-500` (250r + 250s)

+5 итеративных версий: `lite_latest_v{1,2,3}`, `lite_rc_v{1,2}` — ~1500 синтетических примеров. Корпуса различаются после дедупликации; включены как ablation на устойчивость, не как независимые конфигурации.

Синтетика проходит **гуманизацию** — повторный прогон через LLM для сближения со стилем реальных запросов.

Статистический протокол

- **Глобальный тест.** Cochran Q ($k = 12$):

$$Q = \frac{k(k-1)\sum_j (T_j - \bar{T})^2}{k\sum_i R_i - \sum_i R_i^2} \xrightarrow{d} \chi^2(k-1)$$

- **Попарное сравнение.** Точный McNemar по $\binom{12}{2} = 66$ парам.
- **Поправка Бонферрони:** $\alpha_{\text{adj}} = 0{,}05/66 \approx 0{,}0008$.
- **Доверительные интервалы.** Bootstrap ($B = 1000$, seed $= 42$), 95 %-перцентильный метод.
- **Воспроизводимость.** Фиксированные seed, идентификаторы чекпоинтов в Yandex Cloud, единые бенчмарки без ресемплирования.

Главное сравнение: 12 моделей на benchmark-combined

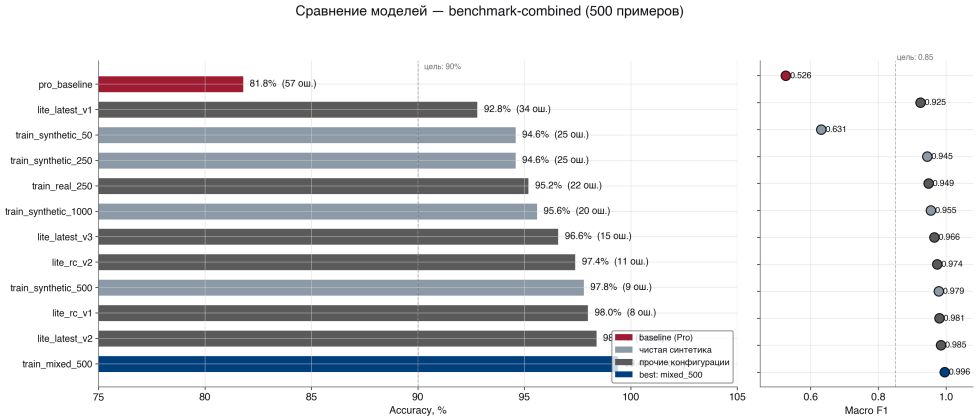

Чемпион — `train_mixed_500`: accuracy $99{,}4\%$, Macro $F_1 = 0{,}996$, 1 ошибка / 500. $\rho_\varnothing$: $6{,}8\% \to 0{,}4\%$.

Кривая насыщения: synthetic vs mixed

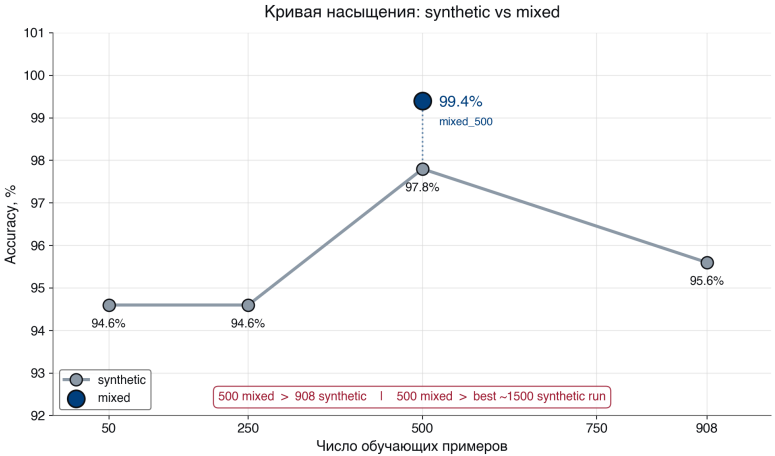

Синтетика: пик $97{,}8\%$ на 500, деградация на 908. 500 mixed $>$ 908 synthetic $>$ best $\sim$1500 synthetic run.

Generalization gap: combined → real

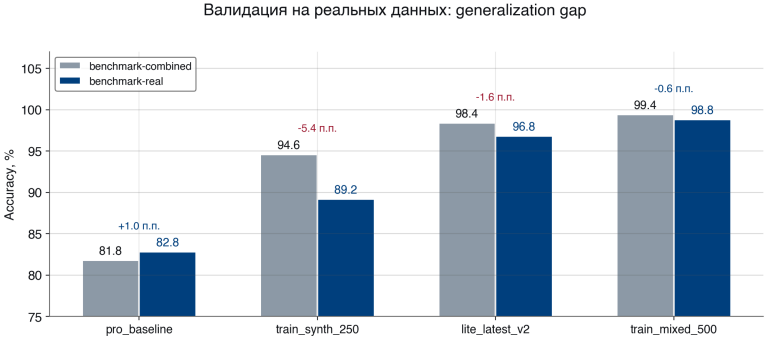

–0.6 п.п.

train_mixed_500 — минимальный gap

–5.4 п.п.

train_synth_250 — максимальный gap

Чисто синтетика теряет $-2{,}2 \ldots -5{,}4$ п.п.; `train_mixed_500` — минимум $-0{,}6$ п.п. ($98{,}8\%$).

Аномалия train_synth_50: «паразитный» класс

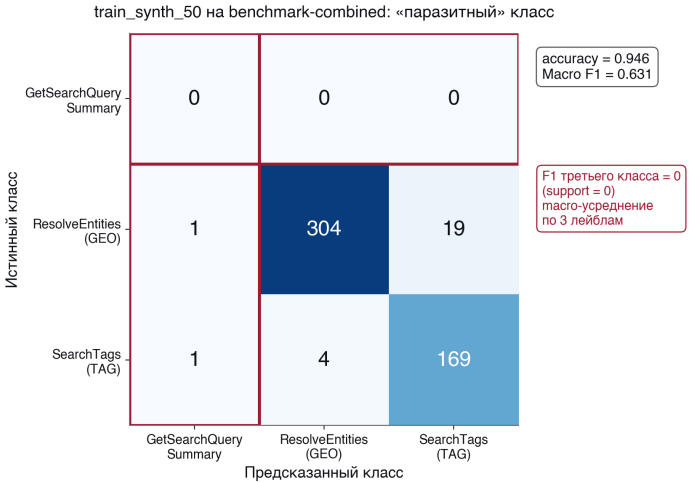

Внешне противоречие:
accuracy $= 0{,}946$, но Macro $F_1 = 0{,}631$.

Объяснение:
модель в 2 случаях из 500 предсказывает несуществующий tool `GetSearchQuerySummary`. F_1 для класса с `support`$= 0$ равен 0; macro-усреднение по 3 лейблам тянет результат вниз.

На 250 примерах паразитный класс исчезает, F_1 восстанавливается до $0{,}945$.

Анализ ошибок: инверсия bias после дообучения

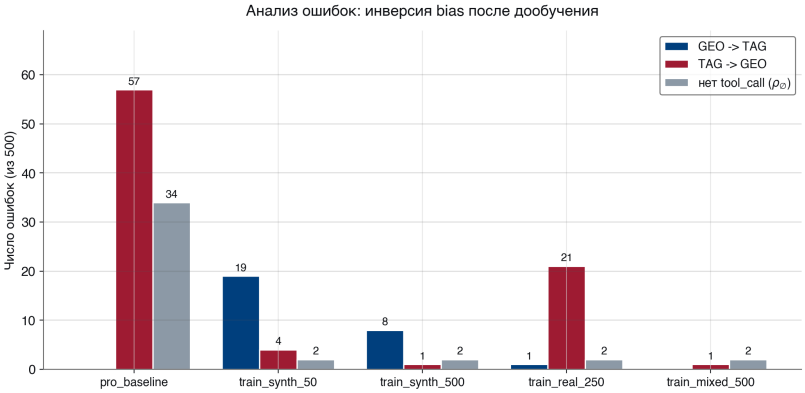

Базовая модель всегда выбирает GEO (57/57 ошибок) — после дообучения bias переворачивается, а mixed_500 устраняет асимметрию

Baseline: 57/57 ошибок $\mathrm{TAG} \to \mathrm{GEO}$.

После synth-обучения bias *переворачивается*. Mixed-500: 0 + 1.

Консервация ошибок: «трудное ядро»

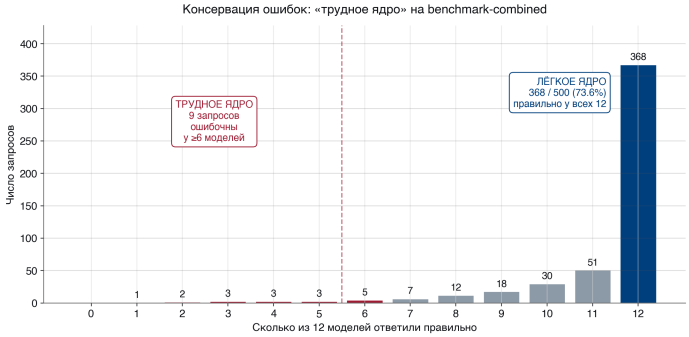

Ни один запрос (k = 0) не ошибочен у всех 12 моделей — каждый в принципе решаем

Статистика по 12 моделям:

- $368/500$ ($73{,}6\%$) — правильно у всех 12;
- 0 запросов ошибочны у всех 12 ($\Rightarrow$ каждый в принципе решаем);
- 9 запросов — у ≥ 6 моделей.

Примеры «трудного ядра»:

- «возле зелёной ветки»
- «у ТТК ищу студию»
- длинные запросы со смешанной геогр. + тег-семантикой

Статистическая значимость различий

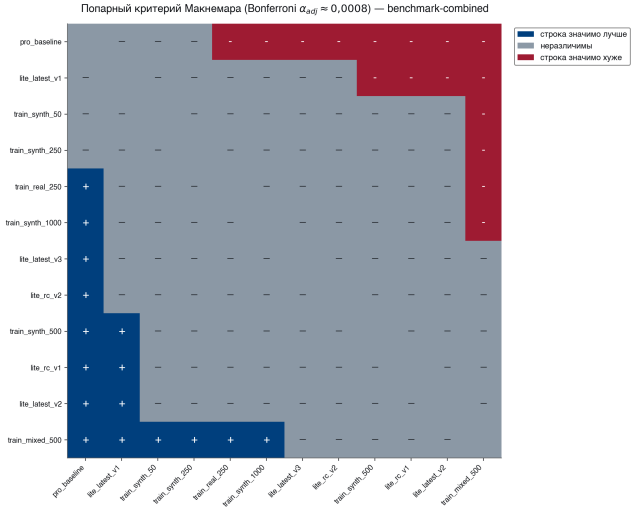

Cochran Q:

- combined: $Q = 348{,}0$
- real: $Q = 128{,}8$
- $p < 10^{-6}$ на обоих

Попарный McNemar:

- `mixed_500` значимо превосходит большинство моделей.
- Неразличимо: `lite_latest_v2` ($p = 0{,}73$), `train_real_250` ($p = 0{,}50$).
- Все чисто синтетические значимо уступают на benchmark-real.

Bootstrap-CI accuracy на benchmark-real

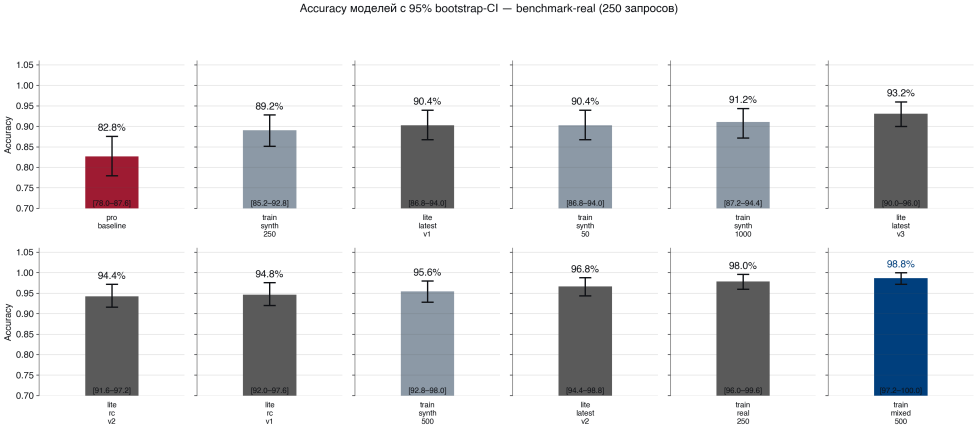

H1b подтверждена: нижняя граница CI `train_mixed_500` $= 0{,}972 > 0{,}90$.

Ответы на исследовательские вопросы

RQ1. LoRA-дообучение поднимает accuracy с $81{,}8\%$ до $99{,}4\%$ ($+17{,}6$ п.п.); все различия значимы.

RQ2. Зависимость немонотонна: 50 примеров уже дают $94{,}6\%$, пик на 500 синтетике, деградация на 908.

RQ3. Тип данных решает: чисто синтетика теряет до $-5{,}4$ п.п. на real; mixed-стратегия даёт $-0{,}6$.

RQ4. H1a, H1b, H2 — подтверждены строгими тестами.

Переносимый рецепт и угрозы валидности

Рецепт адаптации AI-агента:

1. N реальных + M синтетических примеров с балансом $\sim$50/50.
2. LoRA малого ранга вместо full fine-tuning.
3. Обязательная валидация на реальном бенчмарке.
4. Контроль $\rho_{\varnothing}$ (отказы вызова инструмента).

Область применения:
tool routing в AI-ассистентах, enterprise-агенты, оркестрация API-вызовов.

Threats to validity:

- Внутренняя: 1 прогон inference, неуправляемые гиперпараметры LoRA.
- Внешняя: одно семейство моделей (YandexGPT 5.1), 2 инструмента, узкий домен.
- Конструктная: оценивается только первый `tool_call`, не аргументы.
- Статистическая: Bonferroni консервативна при коррелирующих моделях.

Направления дальнейших исследований

- **Альтернативные PEFT-методы.** QLoRA, Adapter Tuning против LoRA при равном бюджете данных.
- **Перенос на другие LLM.** GigaChat, Saiga, ruGPT — проверка универсальности рецепта.
- **Probing-эксперименты.** CKA / linear probes для строгой проверки SAH в decoder-only архитектуре.
- **Масштабирование $|\mathcal{T}| > 2$.** Перенос рецепта на каталог из десятков инструментов.

Спасибо за внимание!

Вопросы?

Студент:	Горошко А. В., группа 22.Б13-мм
Научный руководитель:	доцент кафедры информатики Григорьева А. В.
Рецензент:	ст. преп. кафедры компьютерных технологий и систем, к. ф.-м. н. Севостьянов Р. А.

Санкт-Петербургский государственный университет
Кафедра математики и компьютерных наук

Санкт-Петербург, 2026